

I. Linear regression

A. Dạng cơ bản của Linear regression.

$$F_{w,b}(x) = wx + b$$

w: là giá trị máy tính tự tìm.

x: là giá trị mình nhập vào (train or test).

b: là giá trị máy tính tự tìm.

$F_{w,b}(x)$: là kết quả (tác dụng để tìm kết quả test hay tìm w, b trong train).

B. Cách tìm w, b.

Linear regression model

$$f_{w,b}(x) = wx + b$$

Cost function

$$J(w, b) = \frac{1}{2m} \sum_{i=1}^m (f_{w,b}(x^{(i)}) - y^{(i)})^2$$

Gradient descent algorithm

repeat until convergence {

$$w = w - \alpha \frac{\partial}{\partial w} J(w, b) \rightarrow \frac{1}{m} \sum_{i=1}^m (f_{w,b}(x^{(i)}) - y^{(i)}) x^{(i)}$$

$$b = b - \alpha \frac{\partial}{\partial b} J(w, b) \rightarrow \frac{1}{m} \sum_{i=1}^m (f_{w,b}(x^{(i)}) - y^{(i)})$$

}

m: là tổng số lần mẫu dữ liệu trong tập huấn luyện.

Y: là giá trị dự đoán trong mẫu dữ liệu thứ i dựa trên bộ trọng số w, b.

y: là giá trị thực tế thứ i trong tập huấn luyện.

Giải thích: giá trị α là learning rate cái này do nhập từ ngoài vào người làm phải điều chỉnh, đạo hàm là để giúp bạn nếu giá trị của w, b có giá trị giảm hoặc tăng thì đạo hàm của nó sẽ âm hoặc dương thì lúc đó đạo hàm sẽ giúp kéo nó lại để không bị lệch quá xa.

Correct: Simultaneous update

$$\begin{aligned} \text{tmp_w} &= w - \alpha \frac{\partial}{\partial w} J(w, b) \\ \text{tmp_b} &= b - \alpha \frac{\partial}{\partial b} J(w, b) \\ w &= \text{tmp_w} \\ b &= \text{tmp_b} \end{aligned}$$

Incorrect

$$\begin{aligned} \text{tmp_w} &= w - \alpha \frac{\partial}{\partial w} J(w, b) \\ w &= \text{tmp_w} \\ \text{tmp_b} &= b - \alpha \frac{\partial}{\partial b} J(w, b) \\ b &= \text{tmp_b} \end{aligned}$$

Lưu ý: w, b phải được cập nhật đồng thời. Nghĩa là khi bạn tính đạo hàm cho w và b ở cùng một vòng lặp, bạn bắt buộc phải sử dụng các giá trị cũ của w và b cùng một lúc.

II. Sigmoid function

A. Dạng cơ bản.

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Hàm này chỉ trả ra các giá trị từ (0,1), nó chủ yếu được dùng như 1 hàm kích hoạt.

z: là một số bất kì.

III. Logistic Regression.

A. Dạng cơ bản.

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Hàm này dựa vào hàm Sigmoid function, chỉ khác thay $z = wx+b$.

B. Cách tìm w,b.

Nó khác với tìm w, b trong linear regression, vì đồ thị giá trị sai số của nó khác với linear, trong linear thì chỉ cần tìm giá trị mà ở đó nó là lõm của đồ thị. Mà trong Logistic regression nó lại có quá nhiều lõm nên không thể xác định được lõm nào là đúng nếu dùng cách trên thì nó chỉ cần tìm được lõm thì nó sẽ dừng lại mà cái đáp án đó ko phải đáp án chính xác


Squared error cost

$$\overset{\text{cost}}{J(\vec{w}, b)} = \frac{1}{m} \sum_{i=1}^m \frac{1}{2} (f_{\vec{w}, b}(\vec{x}^{(i)}) - y^{(i)})^2$$

$\text{loss } L(f_{\vec{w}, b}(\vec{x}^{(i)}), y^{(i)})$


linear regression

$$f_{\vec{w}, b}(\vec{x}) = \vec{w} \cdot \vec{x} + b$$



logistic regression

$$f_{\vec{w}, b}(\vec{x}) = \frac{1}{1 + e^{-(\vec{w} \cdot \vec{x} + b)}}$$



Nếu mô hình dự đoán xác suất $f_{w,b}(x) \geq 0.5$, ta kết luận nhãn dự đoán là 1 Ngược lại, ta kết luận nhãn dự đoán là 0.

Cost

$$\begin{aligned} \text{cost} \\ J(\vec{w}, b) &= \frac{1}{m} \sum_{i=1}^m L(\underbrace{f_{\vec{w},b}(\vec{x}^{(i)})}_{\text{loss}}, y^{(i)}) \\ &= \begin{cases} -\log(f_{\vec{w},b}(\vec{x}^{(i)})) & \text{if } y^{(i)} = 1 \\ -\log(1 - f_{\vec{w},b}(\vec{x}^{(i)})) & \text{if } y^{(i)} = 0 \end{cases} \end{aligned}$$

convex
→ can reach a global minimum

find w, b that minimize cost J

Giải thích:

- + Dùng hàm log để chuẩn hóa phép toán cho dễ tính toán, tại vì m có thể là 1 số rất lớn làm cho máy tính bị quá tải, giúp đơn giản việc tính toán.
- + Dùng dấu trừ ở trước để chuyển giá trị âm thành dương vì sigmoid luôn nằm trong khoảng từ (0,1) nên giá trị của log luôn là âm, vì thế thêm dấu trừ để nó chuyển thành dương.
- + Công thức khi mình tính ra nó là tỷ lệ $y^{(i)} = 1$, nên ta có sai số của nó sẽ là chênh kết quả của hàm $f_{w,b}(x)$, ngược lại để tìm tỉ lệ $y^{(i)} = 0$.

Rút gọn của hàm cost function:

Simplified cost function

$$L(\vec{w}, b) = - \sum_{i=1}^m [y^{(i)} \log(f_{\vec{w}, b}(\vec{x}^{(i)})) + (1 - y^{(i)}) \log(1 - f_{\vec{w}, b}(\vec{x}^{(i)}))]$$

loss

$$J(\vec{w}, b) = \frac{1}{m} \sum_{i=1}^m [L(\vec{w}, b)]$$

convex (single global minimum)

$$= - \frac{1}{m} \sum_{i=1}^m [y^{(i)} \log(f_{\vec{w}, b}(\vec{x}^{(i)})) + (1 - y^{(i)}) \log(1 - f_{\vec{w}, b}(\vec{x}^{(i)}))]$$

maximum likelihood (don't)

Gradient descent

cost

$$J(\vec{w}, b) = - \frac{1}{m} \sum_{i=1}^m [y^{(i)} \log(f_{\vec{w}, b}(\vec{x}^{(i)})) + (1 - y^{(i)}) \log(1 - f_{\vec{w}, b}(\vec{x}^{(i)}))]$$

repeat {

$$w_j = w_j - \alpha \frac{\partial}{\partial w_j} J(\vec{w}, b)$$

$$\frac{\partial}{\partial w_j} J(\vec{w}, b) = \frac{1}{m} \sum_{i=1}^m (f_{\vec{w}, b}(\vec{x}^{(i)}) - y^{(i)}) x_j^{(i)}$$

$$b = b - \alpha \frac{\partial}{\partial b} J(\vec{w}, b)$$

$$\frac{\partial}{\partial b} J(\vec{w}, b) = \frac{1}{m} \sum_{i=1}^m (f_{\vec{w}, b}(\vec{x}^{(i)}) - y^{(i)})$$

}

Cách hoạt động giải thích ý chang linear regression.

IV. Chuẩn hóa dữ liệu đầu vào.

A. Điều kiện chuẩn hóa.

Khi dữ liệu nhập trong các đặc trưng có sự chênh lệch nhau quá lớn, tập train hay test gì cũng bị chuẩn hóa. Giúp mô hình dễ hội tụ hơn.

Vd: nhà có 8 phòng mà giá căn nhà lại là 1000000.

B. Cách khắc phục.

Dùng chuẩn hóa hệ số có 2 cách phổ biến nhất:

- Min-Max Scaling (Normalization):

- Nó sẽ nén toàn bộ dữ liệu vào một khoảng cố định phổ biến nhất là [0, 1] hoặc [-1, 1].

$$X_{norm} = \frac{X - X_{min}}{X_{max} - X_{min}}$$

- Các trường hợp thường dùng: Rất phù hợp khi bạn biết rõ giới hạn trên/dưới của dữ liệu (ví dụ: giá trị pixel của ảnh luôn từ 0-255).

- Nhược điểm: Cực kỳ nhạy cảm với các dữ liệu ngoại lai. Nếu gặp 1 giá trị ngoại X_{max} quá lớn thì tập dữ liệu sẽ nhỏ gần giá trị 0.
- Z-score Standardization (Standardization):
 - Thay gì đưa về một khoảng cứng, phương pháp này dời tâm dữ liệu về trung bình $\mu = 0$ và độ lệch chuẩn $\sigma = 1$.
 - Công thức chuyển hóa $X_{std} = \frac{X - \mu}{\sigma}$.
 - Đa số các trường hợp đều dùng được.
 - Điểm mạnh ít bị ảnh hưởng bởi outliers hơn so với Min-Max Scaling, vì nó không phụ thuộc vào giá trị lớn nhất hay nhỏ nhất tuyệt đối.

V. Overfitting.

- A. Các lựa chọn khắc phục.
1. Collect more data. (thu thập nhiều dữ liệu hơn)
 2. Select features. (Chọn lọc đặc trưng)
 - Feature selection.
 3. Reduce size of parameters. (Giảm độ lớn của các tham số)
 - "Regularization". (Điều chuẩn)
- B. Cost function with regularization. (Hàm chi phí chuẩn hóa)

Regularization

$$\min_{\vec{w}, b} J(\vec{w}, b) = \min_{\vec{w}, b} \left[\underbrace{\frac{1}{2m} \sum_{i=1}^m (f_{\vec{w}, b}(\vec{x}^{(i)}) - y^{(i)})^2}_{\text{mean squared error}} + \underbrace{\frac{\lambda}{2m} \sum_{j=1}^n w_j^2}_{\text{regularization term}} \right]$$

fit data ← Keep w_j small
 λ balances both goals

Giải thích: cái công thức cuối sinh ra để giữ cho các trọng số w_j ở mức nhỏ để cho hàm không bị quá khít với các dữ liệu đã cho, để tìm giá trị nhỏ nhất của hàm chi phí tổng. Các hàm logistic regression, linear regression lấy hàm

chi phí cũ cộng với hàm $\frac{\lambda}{2m} \sum_{j=1}^n w_j^2$.

λ là siêu tham số do người dùng nhập vào để điều chỉnh độ cân bằng.

VI. Neural Networks